

Treinamento LLM do Zero – Treinamento Fase 3

Organização: Armando Soares – Coordenador de Desenvolvimento SoberanIA – PIT

Orquestração Multi-Modelo e Governança de LLMs

Unidade I



Gabriel Lopes Bastos
José Victor Vieira de Oliveira

SUMÁRIO

- Evolução do uso de LLMs em ambientes institucionais
- Problemas de uso direto e descentralizado de modelos
- Conceito de orquestração multi-modelo
- Governança, controle e auditoria de IA generativa
- Casos de uso para gateways de LLM

OBJETIVOS DA UNIDADE

- Entender a **evolução do uso de LLMs em ambientes institucionais**
- Identificar **problemas do uso direto e descentralizado de modelos**
- Compreender o **conceito de orquestração multi-modelo**
- Reconhecer a importância de **governança, controle e auditoria**
- Identificar **casos de uso reais para gateways de LLM**
- Entender o papel do **LiteLLM como camada de orquestração**

EVOLUÇÃO DO USO DE LLMS EM AMBIENTES INSTITUCIONAIS

Fase 1

Experimental

- Uso Individual
- Computadores locais
- Chamada direta a API
- **Sem políticas ou segurança**

Fase 2

Departamental


- Times diversos
- Múltiplas Aplicações
- Múltiplos Modelos
- **Credencias Distribuidas**

Fase 3

Institucional

- Diversas Aplicações
- Dados Sensíveis
- Custos Relevantes
- **Exigência de Auditoria**

ARQUITETURA DESCENTRALIZADA



PROBLEMAS DO USO DIRETO E DESCENTRALIZADO DE LLMS



Credenciais Espalhadas

Chaves de API distribuídas em vários repositórios



Logs Inexistentes

Não há registro unificado de quem usou qual modelo ou quando usou



Auditoria Nula

Sem rastreabilidade, inviável realizar investigações



Ausência de Controle de Custo

Gasto desenfreado para qualquer usuário




Políticas Inconsistentes

Cada app define suas próprias regras de acesso, segurança frágil

ARQUITETURA CENTRALIZADA

A centralização do acesso, controle e governança de múltiplos LLMs por meio de um gateway.





Pontos-Chave

- Aplicações não falam mais diretamente com os modelos
- O gateway vira o ponto único de controle institucional

ARQUITETURA COM GATEWAY DE LLM

LLM / AI Gateway Architecture

Aplicações



API GATEWAY

Modelos




OpenAI (GPT, Dall-E, ...)



Google (Bard, Gemini)



AWS Bedrock (Mistral, ...)



Anthropic (Claude, ...)

PAPEL DO LITELLM

LiteLLM não é um modelo, é um orquestrador. Ele não executa, ele controla.

Gateway Unificado



Ponto único de entrada para todos os LLMs da instituição

Mecanismo de Roteamento e Fallback



Direciona para certo modelo conforme regras e contexto e, caso um modelo falhe, redireciona para outro

Observabilidade



Métricas, logs e dashboards de uso em tempo real

Compatível com OpenAI



“OpenAI like”, apps existentes funcionam sem mudança de código

BENEFÍCIOS DA ORQUESTRAÇÃO



Auditoria e Rastreabilidade

Registro de modelos utilizados, usuário que utilizou, custo do uso; com timestamp



Controle de Custo

Quotas por usuário, time ou key; alertas e relatórios de gasto



Políticas Únicas

Rate limits, controle de acesso e filtros definidos uma vez e aplicados em todas as aplicações.



Credenciais Centralizadas

Uma única camada guarda e rotaciona todas as chaves

ORQUESTRAÇÃO VS LOAD BALANCER

Load Balancer tradicional

- Distribui tráfego de rede
- Não entende custo por requisição
- Não audita conteúdo das requisições
- Fallback apenas por disponibilidade
- Sem noção de política de acesso

Orquestrador de LLMs

- Roteia com base em semântica e contexto
- Controla e contabiliza custo por token
- Audita prompts, respostas e metadados
- Fallback inteligente por custo e qualidade
- Aplica rate limiting e quotas por usuário

O QUE É GOVERNANÇA EM IA GENERATIVA

Governança é o conjunto de políticas, controles e responsabilidades que regulam como modelos de IA são utilizados em uma instituição, não para restringir, mas para garantir uso **seguro, rastreável e sustentável**.

Ela define:

- Quem pode usar
- Qual modelo pode ser usado
- Em quais contextos
- Com quais limites
- Com qual auditoria



CONTROLE DE USO E AUDITORIA

Controle abrange os mecanismos que regulam o acesso e o uso dos modelos em tempo real.

Auditoria é o registro sistemático dessas interações, permitindo rastreabilidade, análise de custos e investigação de incidentes.

Juntos, garantem que a **governança** saia do papel e funcione na prática.

Seus elementos essenciais:

- Autenticação e autorização
- Rate limiting
- Quotas por usuário/aplicação
- Logs de prompts e respostas
- Relatórios de uso e custo



IMPORTÂNCIA DA AUDITORIA

Em ambientes institucionais, o uso de LLMs sem registros confiáveis é um risco operacional, legal e reputacional. A auditoria é o que torna esse uso defensável. Ela permite:

- Responsabilização
- Rastreabilidade
- Análise de custos
- Investigação de incidentes
- Conformidade legal



CASOS DE USO

Gateways de LLM se aplicam onde o volume, a diversidade de modelos e a necessidade de governança e auditoria tornam o acesso direto inviável e irresponsável.

Institucionais

- Universidades com múltiplos chatbots departamentais
- Órgãos públicos com dados sensíveis e exigência de conformidade
- Projetos RAG institucionais com fontes internas
- Ambientes híbridos com modelos locais e remotos

Corporativos

- Múltiplos produtos consumindo LLMs com controle de custo por time
- Fallback automático entre modelos por disponibilidade ou custo
- Migração gradual entre fornecedores sem impacto nas aplicações


ORQUESTRAÇÃO E SOBERANIA DIGITAL

Soberania digital é a capacidade de uma instituição manter controle sobre seus dados, suas decisões tecnológicas e sua infraestrutura de IA.

A **orquestração** multi-modelo é um dos pilares que viabiliza essa soberania na prática.

Benefícios estratégicos:

- Dados sob controle institucional
- Uso de modelos soberanos
- Flexibilidade tecnológica
- Redução de dependência externa



BOAS PRÁTICAS INICIAIS

Para uma adoção segura e sustentável de LLMs em ambiente institucional, algumas práticas são recomendadas desde o início:

- Centralizar o acesso aos LLMs
- Definir políticas claras de uso
- Separar ambientes de desenvolvimento e produção
- Registrar uso e custos
- Documentar decisões arquiteturais

O LiteLLM endereça boa parte dessas práticas nativamente, como veremos nas próximas unidades.

CONCLUSÃO DA UNIDADE

Resumindo o que foi visto na unidade I:

- LLMs evoluem do uso experimental à adoção institucional — e essa escala exige controle
- O uso descentralizado gera riscos reais de segurança, custo e rastreabilidade
- Orquestração multi-modelo centraliza acesso e simplifica a gestão de múltiplos LLMs
- Governança define quem usa, o quê, como e com qual responsabilidade
- Gateways de LLM viabilizam auditoria, políticas e flexibilidade em produção
- O LiteLLM é a camada que transforma esses princípios em infraestrutura real



Obrigado pela atenção!

Fim da Unidade I



Próxima Unidade:
Arquitetura e Funcionamento do LiteLLM